

Федеральное государственное автономное образовательное учреждение
высшего образования

Московский физико-технический институт
(национальный исследовательский университет)
Физтех-школа прикладной математики и информатики
Кафедра алгоритмов и технологий программирования

Направление подготовки / специальность: 09.04.01 Информатика и
вычислительная техника

Направленность (профиль) подготовки: Прикладная математика и
информатика

Спектральные характеристики представлений в CNN и трансформерах

(магистерская диссертация)

Студент:

Шамигулов Искандер Ильгамович

Научный руководитель:

Калмыков Николай Игоревич

Долгопрудный

2026

Аннотация

В работе исследуется, как распределение спектральной энергии по пространственным частотам меняется с глубиной в трёх семействах моделей компьютерного зрения: сверточной ResNet, визуальном трансформере ViT и иерархическом трансформере Swin.

Центральный вклад работы — разработка единого протокола спектрального анализа, впервые позволяющего корректно и непротиворечиво сравнивать разнородные архитектуры. В отличие от предыдущих исследований, протокол явно различает радиальную среднюю мощность (для визуализации) и суммарную энергию колец (для метрик), а также включает контрольные эксперименты, отделяющие эволюцию признаков от тривиального эффекта уменьшения разрешения.

Эксперименты на ImageNet 10K показали: ResNet демонстрирует наиболее устойчивое низкочастотное сжатие; ViT на фиксированной решётке патчей ведёт себя немонотонно; Swin приходит к низкочастотному финальному профилю, но во многом за счёт иерархического понижения разрешения.

Научная новизна состоит в том, что впервые проведено прямое сопоставление спектральной динамики трёх принципиально разных типов архитектур в едином методическом ключе. Предложенный протокол может служить самостоятельным диагностическим инструментом при выборе архитектуры для задач, чувствительных к пространственной структуре признаков.

Содержание

1. Введение	5
2. Теоретические сведения	11
2.1. Внутренние представления и частотная интерпретация	11
2.2. Архитектуры компьютерного зрения	16
2.3. Спектральные свойства нейронных сетей	20
2.4. Выводы по теоретической главе	23
3. Методы	25
3.1. Спектральный анализ	25
3.2. Метрики	33
3.3. Экспериментальная постановка	35
4. Результаты	39
4.1. Спектральные кривые	39
4.2. Сводная интерпретация по метрикам	50
4.3. Обобщение экспериментальных результатов	55
5. Заключение	57
Список литературы	61

Глава 1

Введение

Современное компьютерное зрение уже давно не сводится только к подбору архитектуры с максимальной точностью на тестовой выборке. Да, итоговое качество модели остаётся главным практическим показателем. Но оно почти ничего не говорит о том, как именно модель преобразует изображение внутри себя. Две архитектуры могут давать близкий ответ на выходе, но строить совершенно разные промежуточные представления. Собственно, это и делает анализ внутренних признаков отдельной исследовательской задачей.

За последние годы в задачах зрения сложилось несколько крупных архитектурных семейств. Сначала основным инструментом были свёрточные нейронные сети. Затем широкое распространение получили остаточные сети ResNet, которые позволили устойчиво обучать более глубокие CNN за счёт остаточных связей [1]. Позже в компьютерное зрение пришли визуальные трансформеры. Vision Transformer разбивает изображение на патчи и обрабатывает их как последовательность токенов [2]; эта идея опирается на архитектуру Transformer, предложенную для последовательностей [3]. Ещё один важный вариант — Swin Transformer, где трансформерная обработка сочетается с иерархией, оконным вниманием, сдвигом окон и объединением патчей [4]. Получается три разных способа работы с изображением: свёрточная пирамида, токенная модель с фиксированной решёткой патчей и иерархический трансформер.

Внутри нейронной сети изображение постепенно превращается в набор признаков. В ранних слоях эти признаки часто ближе к локальным

изменениям: границам, текстурам, цветовым переходам. На более глубоких уровнях представления обычно становятся более агрегированными. Но здесь нельзя делать слишком прямой вывод. Глубокий слой — это не обязательно «только семантика», а ранний — не обязательно «только текстура». Это скорее удобная интуиция, которую нужно проверять количественно.

Один из способов такой проверки — перейти к частотной области. Изображение можно рассматривать как сигнал, состоящий из компонент разного масштаба. Низкие пространственные частоты связаны с плавными изменениями и крупными структурами, более высокие — с резкими переходами, границами, текстурными и шумовыми компонентами. Если рассматривать не только исходное изображение, но и внутренние представления модели, появляется естественный вопрос: как по глубине меняется распределение энергии по частотам?

Для CNN такой вопрос возникает почти сразу. Карты признаков имеют двумерную пространственную структуру, а сама операция свёртки тесно связана с фильтрацией сигнала. При этом в ResNet между стадиями уменьшается пространственное разрешение. Значит, если в глубоких слоях виден более узкий спектр, нельзя автоматически считать это только свойством обученных признаков. Часть эффекта может быть обычным следствием уменьшения размера карты признаков. Поэтому в данной работе отдельно проверяется, насколько спектральное сжатие ResNet сохраняется после контроля этого фактора.

С ViT ситуация другая. Модель работает с последовательностью патчевых токенов и в стандартной конфигурации сохраняет одну и ту же патчевую решётку по глубине. Это делает ViT удобным контрастом к ResNet: если спектральный профиль меняется между блоками, то это изменение уже нельзя объяснить межстадийным уменьшением пространственного разрешения. При этом не стоит сразу приписывать наблюдаемую динамику одному только самовниманию. На результат влияют остаточные связи, нормализации, MLP-блоки, позиционные эмбединги и способ кодирования патчей. Работы по визуальным трансформерам уже показывали, что их внутренние представления отличаются от CNN [5], а механизм са-

мовнимания может проявлять низкочастотные свойства [6]. Но это не означает, что все блоки ViT обязаны монотонно смещаться к низким частотам.

Swin Transformer занимает промежуточное положение. Он использует токены и механизм внимания, но при этом строит иерархию и уменьшает размер токеной решётки через объединение патчей [4]. Поэтому для Swin особенно важно не смешивать два эффекта: изменение самих признаков и уменьшение пространственного разрешения. В этой работе Swin рассматривается именно как архитектура, где эти два фактора нужно разделять аккуратно.

Теоретическая мотивация исследования связана с работами о частотном смещении нейронных сетей. В [7] показано, что нейронные сети обычно быстрее осваивают низкочастотные компоненты функций. Позже эта линия развивалась в исследованиях принципа частотного обучения и способов измерения частотного смещения [8, 9]. В задачах компьютерного зрения частотные компоненты также связывают с устойчивостью и обобщающей способностью моделей [10, 11]. В данной работе эти результаты используются как основание для постановки вопроса, но не как готовое объяснение. Спектр показывает, как распределена энергия. Он не доказывает сам по себе, какие частоты полезны для классификации.

Отсюда и появляется основная идея работы. Нужно не просто построить красивые спектральные кривые, а сделать сравнение доказательным: использовать единый протокол для разных архитектур, корректно считать радиальные метрики, учитывать число точек в радиальных кольцах, задавать единый частотный масштаб и проверять влияние уменьшения разрешения там, где оно есть. Без этого легко перепутать реальное изменение представлений с техническим эффектом пространственной дискретизации.

Цель данной выпускной квалификационной работы — исследовать спектральные характеристики внутренних представлений ResNet, ViT и Swin и определить, как тип архитектуры связан с перераспределением спектральной энергии по глубине модели.

Для достижения этой цели были поставлены следующие задачи:

-
1. изучить теоретические основы спектрального анализа нейросетевых представлений и связанные исследования по частотному смещению, CNN и визуальным трансформерам;
 2. описать архитектурные особенности ResNet, ViT и Swin, влияющие на пространственную структуру представлений;
 3. реализовать единый протокол извлечения промежуточных представлений из моделей разных архитектур;
 4. адаптировать спектральный анализ к токенистым представлениям ViT и Swin через восстановление двумерной решётки патчей;
 5. построить радиальные спектральные кривые для выбранных уровней моделей;
 6. рассчитать спектральный центроид, долю низкочастотной энергии и коэффициент экспоненциального спектрального сжатия;
 7. добавить стандартные отклонения по изображениям выборки и использовать их при интерпретации таблиц и графиков;
 8. провести контрольные эксперименты для ResNet и Swin, чтобы отделить изменение спектрального профиля от простого уменьшения пространственного разрешения;
 9. сравнить спектральную динамику внутри каждого архитектурного семейства и между семействами ResNet, ViT и Swin.

Объектом исследования являются внутренние представления моделей компьютерного зрения. Предметом исследования являются спектральные характеристики этих представлений: распределение энергии по пространственным частотам, изменение радиального спектрального профиля по глубине модели и различия между архитектурными семействами.

В качестве экспериментальных объектов используются три семейства моделей. ResNet рассматривается как представитель иерархических свёрточных архитектур. Vision Transformer используется как пример модели, работающей с последовательностью патчевых токенов. Swin Transformer

выбран как иерархический трансформер с локальной оконной обработкой и уменьшением токеной решётки. Эксперименты проводятся на подвыборке ImageNet 10K [12], основанной на классическом наборе ImageNet [13].

В работе проверяются три исследовательских предположения.

Первое предположение состоит в том, что ResNet по мере перехода к глубоким стадиям демонстрирует снижение спектрального центроида и рост доли низкочастотной энергии. При этом отдельно проверяется, какая часть этой динамики связана с уменьшением пространственного разрешения между стадиями.

Второе предположение связано с ViT. Поскольку стандартный ViT сохраняет фиксированную решётку патчей по глубине, его спектральная динамика не обязана повторять монотонное низкочастотное сжатие CNN. Ожидается, что изменение спектра будет более немонотонным.

Третье предположение относится к Swin. Из-за иерархической структуры и объединения патчей Swin может приходить к более низкочастотному финальному профилю, но часть этого эффекта, возможно, будет объясняться уменьшением токеной решётки. Поэтому для Swin особенно нужен контроль влияния разрешения.

Научная новизна работы состоит в том, что спектральная динамика ResNet, ViT и Swin сравнивается в едином экспериментальном протоколе, но с учётом архитектурных различий. Для графиков используется радиальная средняя мощность, а для численных метрик — суммарная энергия по радиальным кольцам. Это снимает методическую проблему, при которой радиальное среднее ошибочно трактуется как доля энергии. Также в работе добавлены контрольные эксперименты для ResNet и Swin, позволяющие отделить эффект уменьшения разрешения от изменения самих представлений.

Практическая значимость работы состоит в том, что предложенный протокол можно использовать как дополнительный инструмент диагностики моделей компьютерного зрения. Он показывает, где по глубине модели происходит сдвиг энергии к низким частотам, где сохраняется среднечастотный хвост и насколько этот эффект связан с архитектурной иерархи-

ей. Такой анализ может быть полезен при сравнении архитектур для задач, где пространственная структура признаков имеет значение: медицинские изображения, спутниковые снимки, дефектоскопия, текстурный анализ и задачи с мелкими объектами. При этом в данной работе не делается прямой вывод о полезности конкретных частот для качества классификации. Для этого нужен отдельный эксперимент.

Структура работы следующая. Во второй главе вводятся теоретические сведения: внутренние представления, частотное описание изображений, радиальные спектры, круг Найквиста, ResNet, ViT, Swin и связанные исследования. В третьей главе описывается методика: извлечение представлений, построение спектра мощности, радиальное представление, расчёт метрик и контрольные эксперименты. В четвёртой главе приведены результаты: спектральные кривые, таблицы метрик, сравнение архитектур и проверка влияния уменьшения разрешения. В пятой главе формулируются основные выводы, ограничения и направления дальнейшей работы.

Глава 2

Теоретические сведения

Данная глава вводит понятия, которые дальше используются в методике и в интерпретации результатов. Здесь рассматриваются внутренние представления нейронных сетей, частотное описание изображений и карт признаков, радиальные спектры, круг Найквиста, а также архитектуры ResNet, Vision Transformer и Swin Transformer. Отдельно оговариваются ограничения спектральной интерпретации: спектр показывает распределение энергии по пространственным частотам, но сам по себе не доказывает, какие признаки являются полезными для классификации.

2.1 Внутренние представления и частотная интерпретация

2.1.1 Внутренние представления моделей компьютерного зрения

Глубокую нейронную сеть можно рассматривать как последовательность преобразований входного изображения. На вход подаётся тензор пикселей, на выходе получается предсказание класса или другой целевой результат. Между ними находятся промежуточные слои. Их выходы обычно называют внутренними представлениями, признаками или активациями.

Внутреннее представление показывает, в какой форме модель хранит информацию об изображении на некотором этапе обработки. В ранних слоях признаки часто ближе к исходному изображению: они могут реагировать на локальные границы, контуры, текстуры и цветовые переходы. В более глубоких слоях признаки обычно становятся менее привязанными к отдельным пикселям и могут описывать более крупные части объектов

или повторяющиеся структуры. Это не означает, что каждый глубокий слой всегда содержит только «семантику», а каждый ранний — только «текстуру». Такая граница грубая. Но как рабочее описание она полезна.

Для свёрточных сетей внутренние представления имеют вид карт признаков. Карта признаков — это двумерная сетка значений, заданная для каждого канала. Если исходное изображение содержит три цветовых канала, то глубокий слой сети может содержать сотни или тысячи каналов. Каждый канал можно рассматривать как отдельный тип отклика, который сеть сформировала в процессе обучения.

В трансформерных архитектурах представления устроены иначе. Изображение разбивается на патчи, после чего каждый патч переводится в вектор — токен. Дальше модель работает не с плотной картой пикселей, а с последовательностью токенов. Чтобы применить к таким представлениям двумерный спектральный анализ, токены возвращают в решётку, соответствующую расположению патчей в исходном изображении. Это удобно, но здесь есть нюанс: такая решётка не является полной копией карты признаков CNN. Один токен уже содержит агрегированную информацию о целом фрагменте изображения.

Классическая работа [14] показывает, что признаки разных уровней обладают разной переносимостью между задачами. Ранние признаки часто более универсальны, поздние сильнее зависят от конкретного набора данных и задачи. В данной работе этот взгляд дополняется частотной интерпретацией: нас интересует, как по глубине модели меняется распределение энергии внутренних представлений по пространственным частотам.

2.1.2 *Изображение как пространственный сигнал*

Изображение можно рассматривать как пространственный сигнал, заданный на двумерной координатной сетке. В каждой точке этой сетки находится значение яркости или цвета. Если при движении по изображению значения меняются плавно, это соответствует низким пространственным частотам. Если значения резко меняются от точки к точке, речь идёт о более высоких частотах.

Плавный фон, крупный силуэт объекта и большие однородные области обычно дают вклад в низкие частоты. Резкие границы, тонкие линии, мелкие текстуры и шум связаны с более высокими частотами. Реальное изображение почти всегда содержит оба типа компонент. Например, фотография животного содержит низкочастотную информацию о форме тела и фоне, а также более высокочастотную информацию о шерсти, краях и мелких деталях.

В задачах компьютерного зрения это различие имеет смысл. Для грубого различения объектов часто достаточно общей формы. Для задач, где решают мелкие отличия, высокочастотные компоненты могут быть существенными. При этом нельзя автоматически считать высокие частоты «полезными», а низкие — «недостаточными». В высоких частотах может находиться и шум, а низкие частоты могут давать устойчивое описание крупной структуры. Поэтому дальше частотный анализ используется как способ описания представлений, а не как готовая оценка их качества.

2.1.3 Дискретное преобразование Фурье, DC-компонента и спектр мощности

Спектр описывает сигнал через набор частотных компонент. В пространственной области мы смотрим, как значения расположены по координатам. В частотной области — из каких изменений разного масштаба состоит сигнал. Для двумерных изображений и карт признаков используется двумерное дискретное преобразование Фурье.

В спектральном анализе различают амплитуду, фазу и энергию. Амплитуда показывает силу частотной компоненты, фаза связана с её пространственным положением, а энергия описывает вклад частоты в общий сигнал. В данной работе анализируется спектр мощности, то есть квадрат модуля коэффициентов Фурье. Такой выбор связан с целью исследования: нужно сравнить не точное положение структур в пространстве, а распределение энергии между частотными диапазонами.

Отдельно нужно упомянуть нулевую частоту, или DC-компоненту. Она соответствует постоянной составляющей сигнала, то есть его сред-

нему значению. В картах признаков DC-компонента может быть очень большой и визуально скрывать различия между ненулевыми частотами. Поэтому перед преобразованием Фурье из каждой карты признаков вычитается пространственное среднее. В методической главе этот шаг описан отдельно, поскольку он влияет на форму спектральных кривых.

После вычисления преобразования Фурье обычно применяется операция `fftshift`: нулевая частота переносится в центр спектра. Тогда малые радиусы вокруг центра соответствуют низким частотам, а удаление от центра — переходу к более высоким частотам. Такое представление удобно для радиального анализа.

2.1.4 Частотный радиус, круг Найквиста и радиальное представление

Двумерный спектр содержит информацию и о масштабе частоты, и о её направлении. Например, горизонтальная и вертикальная граница могут иметь похожий частотный масштаб, но разные направления в частотной плоскости. В данной работе направление отдельно не анализируется. Меня интересует зависимость энергии от частотного радиуса, то есть от расстояния частотной точки до центра спектра.

Радиус частотной точки после `fftshift` определяется как расстояние до центра спектра:

$$r(u, v) = \sqrt{(u - u_0)^2 + (v - v_0)^2},$$

где (u_0, v_0) — координаты центра. Частоты с близкими значениями радиуса объединяются в кольца. Так двумерная карта спектра превращается в одномерный радиальный профиль.

Для карт признаков конечного размера максимальная представимая частота ограничена частотой Найквиста. В одномерном случае это половина частоты дискретизации. В двумерном случае ситуация чуть менее очевидна, потому что частотная плоскость имеет горизонтальное, вертикальное и диагональное направления. В работе используется радиус

$$R_{\max} = \frac{\min(H, W)}{2}.$$

Такой выбор соответствует анализу внутри круга Найквиста, вписанного в частотную плоскость. Это делает сравнение разных направлений более аккуратным: в расчёт не включаются диагональные области, которые выходят за пределы горизонтальной или вертикальной границы Найквиста.

Нормированный радиус задаётся как

$$\rho = \frac{r}{R_{\max}}.$$

После такой нормализации $\rho = 0$ соответствует центру спектра, а $\rho = 1$ — границе выбранного круга Найквиста. В результатах дополнительно используется масштабирование частотной оси к разрешению начального слоя, чтобы сравнивать слои с разным пространственным размером на общей оси. Собственно, без этого поздние слои ResNet и Swin нельзя было бы напрямую сопоставлять с ранними: у них просто другой доступный диапазон частот.

2.1.5 Радиальное среднее и радиальная энергия

В радиальном анализе есть два близких, но разных объекта. Первый — средняя мощность в кольце. Она получается, если суммарную мощность на радиусе разделить на число точек в этом кольце. Такая кривая хорошо подходит для визуализации: дальние кольца не становятся больше только из-за того, что в них больше частотных точек.

Второй объект — суммарная энергия кольца. Она нужна для метрик. Если требуется посчитать долю энергии в низких частотах, нельзя брать только среднее значение в кольце: кольца разного радиуса содержат разное число точек. Поэтому в методике для графиков используется радиальная средняя мощность, а для центроида и доли низкочастотной энергии — суммарная энергия кольца с последующей нормализацией. Это различие важно, потому что иначе величина, названная долей энергии, на самом деле не будет учитывать количество частотных компонент в диапазоне.

2.1.6 Интерпретация низких и высоких частот

В обычной обработке изображений низкие частоты связывают с крупной формой и плавными областями, а высокие — с мелкими деталями, границами, текстурами и шумом. Для внутренних представлений нейронных сетей эта интерпретация сохраняется только частично. Карта признаков — это уже не исходное изображение, а отклик некоторого набора фильтров или токенных преобразований. Поэтому низкая частота в карте признаков означает пространственно плавное распределение признака, а высокая — быстрое изменение этого признака по координатам.

По этой причине выводы должны быть осторожными. Если спектр глубокого слоя сдвигается к низким частотам, это может соответствовать более гладкому и агрегированному представлению. Но это не доказывает автоматически, что модель «лучше понимает объект» или что высокие частоты стали ненужными. Аналогично, широкий хвост спектра может отражать сохранение локальных различий, но не доказывает, что эти различия полезны для классификации.

Частотные компоненты действительно связаны с поведением моделей компьютерного зрения. Например, работа [10] рассматривает устойчивость моделей через призму частотной области, а в [11] обсуждается роль высокочастотных компонент в обобщающей способности CNN. Для данной диссертации эти работы используются как контекст. В самой экспериментальной части не проверяется причинная роль конкретных частот для качества модели. Проверяется другое: как архитектуры меняют спектральный профиль внутренних представлений.

2.2 Архитектуры компьютерного зрения

2.2.1 Свёрточные нейронные сети и ResNet

Свёрточная нейронная сеть — это архитектура, рассчитанная на данные с пространственной структурой. В изображении соседние пиксели обычно связаны друг с другом, и CNN использует это свойство через локальные фильтры. Один и тот же фильтр применяется ко всем пространственным

позициям, поэтому сеть может находить похожие структуры в разных частях изображения.

Для понимания CNN нужны несколько терминов. Канал — отдельная карта признаков. Ядро свёртки — небольшой набор весов, который применяется к локальному участку входа. Шаг свёртки задаёт, как фильтр перемещается по координатам. Если шаг больше единицы, пространственное разрешение уменьшается. Понижение разрешения также может выполняться через пулинг. Рецептивное поле — это область исходного изображения, которая влияет на значение в конкретной позиции карты признаков.

С точки зрения спектрального анализа CNN естественно рассматривать как иерархическую систему локальных преобразований. Ранние уровни работают с более плотной пространственной сеткой. Поздние уровни часто имеют меньшее разрешение и большее рецептивное поле. Поэтому при переходе к глубоким слоям можно ожидать смещение спектральной энергии к более низким частотам. Но здесь есть методический риск: часть этого сдвига может быть простой геометрией, а не изменением самих признаков. Когда разрешение карты уменьшается, доступный диапазон частот тоже уменьшается. Именно поэтому в результатах используются контрольные эксперименты на понижение разрешения.

Семейство ResNet основано на остаточных связях [1]. Остаточная связь позволяет блоку обучать не полное преобразование входа, а добавку к нему. За счёт этого глубокие сети легче оптимизируются, а градиент проходит через модель устойчивее. Для данной работы ResNet удобна как представитель классической иерархической CNN: внутри одного семейства доступны модели разной глубины — ResNet18, ResNet34, ResNet50 и ResNet101.

В экспериментальной части ResNet анализируется по четырём крупным стадиям: `layer1`, `layer2`, `layer3` и `layer4`. Это не отдельные операции, а группы блоков. Между стадиями меняются разрешение, число каналов и эффективный масштаб признаков. Поэтому результаты по ResNet нужно читать вместе с контролем: отдельно смотрится общая динамика по стадиям и отдельно проверяется, что происходит при искусственном

уменьшении разрешения раннего слоя.

2.2.2 *Transformer и механизм самовнимания*

Transformer возник как архитектура для обработки последовательностей, в которой основной обмен информацией между элементами строится через механизм самовнимания [3]. В свёрточной сети локальность задаётся фильтром. В Transformer токены смешиваются через веса внимания, которые вычисляются из самих представлений.

Механизм самовнимания можно описать как адаптивное смешивание токенов. Для каждого токена модель оценивает, какие другие токены сильнее участвуют в его обновлении. Многоголовое внимание делает это в нескольких параллельных подпространствах. Но обычный блок трансформера не состоит только из внимания. В нём есть нормализация, MLP-блок и остаточные связи. Поэтому спектральное поведение трансформера нельзя вывести только из матрицы внимания.

В литературе самовнимание иногда рассматривают как оператор с низкочастотными свойствами. Например, в работе [6] показано, что внимание может вести себя как низкочастотный фильтр. Но переносить этот вывод на весь Vision Transformer (ViT) напрямую нельзя. Полный блок содержит несколько операций, и их совместное действие может дать немонотонный спектральный профиль. В данной работе это как раз проверяется экспериментально: если у ViT спектр не сжимается монотонно, это не противоречит идее о сглаживающих свойствах внимания, потому что анализируется выход всего блока, а не изолированный оператор внимания.

2.2.3 *Vision Transformer*

Vision Transformer переносит трансформерный подход на изображения [2]. Изображение разбивается на непересекающиеся патчи. Например, при размере входа 224×224 и размере патча 16×16 получается решётка 14×14 , то есть 196 патчей. Каждый патч разворачивается в вектор и проходит через линейную проекцию. После этого он становится токеном.

Чтобы модель различала расположение патчей, к токенам добавляются позиционные эмбединги. В классификационных версиях ViT обычно используется CLS-токен. Он не соответствует отдельному участку изображения и не является позиционным эмбедингом; его задача — агрегировать информацию для классификационного выхода. В методике CLS-токен исключается перед построением спектра, потому что у него нет координаты в двумерной решётке патчей.

ViT отличается от CNN не только наличием внимания. У него другая начальная дискретизация изображения: один токен соответствует целому патчу. При этом внутри стандартного ViT размер патчевой решётки сохраняется одинаковым по блокам. Поэтому изменения спектра между блоками нельзя объяснить межстадийным уменьшением разрешения, как в ResNet или Swin. Это делает ViT удобным контрастным случаем для проверки: меняется ли спектральный профиль при фиксированной решётке.

Сравнение ViT и CNN подробно обсуждается в [5]. Авторы показывают, что визуальные трансформеры иначе распределяют информацию по глубине и раньше используют глобальные связи. Для данной работы это означает, что спектральная динамика ViT не обязана повторять поведение ResNet. Но в тексте результатов это формулируется как наблюдение по спектрам и метрикам, а не как доказательство конкретного механизма внимания.

2.2.4 *Swin Transformer*

Swin Transformer был предложен как иерархическая трансформерная архитектура для изображений [4]. В отличие от классического ViT, он не использует глобальное внимание по всем токенам на каждом блоке. Внимание вычисляется внутри локальных окон, а на соседних блоках окна сдвигаются. Такой механизм называется оконным смещением (shifted windows).

Ещё один элемент Swin — слияние патчей (patch merging). Эта операция объединяет соседние патчи, уменьшает пространственное разрешение и увеличивает число каналов. По смыслу она похожа на понижение раз-

решения в CNN. Благодаря этому Swin строит многостадийную иерархию: ранние стадии имеют более плотную решётку, поздние — меньшую решётку и более агрегированные признаки.

С точки зрения спектрального анализа Swin интересен именно как промежуточный случай. С одной стороны, он использует токены и внимание. С другой стороны, у него есть стадии и уменьшение разрешения, как у CNN. Поэтому можно ожидать, что его финальные представления будут более низкочастотными. Однако объяснять это только оконным вниманием или сдвигом окон нельзя. В данной работе не проводится анализ вклада, где отдельно отключаются оконные сдвиги или слияние патчей. Поэтому в результатах такие объяснения используются только как возможная интерпретация. Проверенный факт — форма спектральных кривых и значения метрик.

2.3 Спектральные свойства нейронных сетей

2.3.1 Спектральное смещение и принцип частот

Одно из направлений в теории глубокого обучения связано с понятием *spectral bias*, или спектрального смещения. Под этим понимается склонность нейронных сетей легче осваивать низкочастотные зависимости, чем высокочастотные. Иначе говоря, более гладкие компоненты функции часто усваиваются раньше, а более резкие зависимости оказываются сложнее.

Работа [7] является одной из основных в этом направлении. В ней показано, что глубокие сети с ReLU-активациями обладают смещением в сторону низких частот. Это не означает, что сеть не может выучить высокочастотную функцию. Скорее речь о том, что низкочастотные закономерности оказываются для неё более естественными в процессе обучения.

Эта идея развивалась в рамках *frequency principle* [8]. В работе [9] рассматриваются способы вычислимого определения спектрального смещения, то есть переход от качественного описания к более формальному измерению. Работа [15] показывает, что Фурье-признаки могут помогать сетям лучше представлять высокочастотные функции.

Для данной диссертации эти работы задают общий фон. Но есть принципиальная разница: spectral bias обычно говорит о процессе обучения функции, а в данной работе анализируются уже обученные модели и их внутренние представления. Поэтому результаты не следует напрямую отождествлять с динамикой обучения. Здесь исследуется не то, какие частоты модель учит первыми, а то, как распределена энергия признаков в готовых представлениях.

2.3.2 Частоты, устойчивость и трансформерные модели

Частотная область часто используется для анализа устойчивости и поведения моделей компьютерного зрения. В работе [10] искажения рассматриваются в частотной области, что позволяет изучать чувствительность моделей к изменениям разных масштабов. В [11] обсуждается роль высокочастотных компонент в обобщающей способности CNN. Эти работы показывают, что частотный состав входа и признаков может быть связан с поведением модели.

Для визуальных трансформеров вопрос частот также обсуждается в нескольких работах. Исследования [16–18] показывают, что ViT могут отличаться от CNN по внутренней организации признаков и устойчивости. Работа [19] отдельно рассматривает высокочастотные компоненты в ViT. Всё это поддерживает идею, что CNN и трансформеры стоит сравнивать не только по итоговой точности, но и по структуре внутренних представлений.

При этом в данной работе не проверяется устойчивость и не проводится оценка причинной роли отдельных частот. Частотные исследования используются как контекст, а экспериментальная часть ограничивается спектральным анализом промежуточных представлений.

2.3.3 Частотно-ориентированные методы в глубоком обучении

Частотная область используется не только для анализа, но и для построения новых методов. В работе [20] рассматривается обучение в частотной области. Работа [21] показывает использование частотного домена в CNN для задач диагностики и адаптации домена. В более широком кон-

тексте глубокое обучение активно применяется к спектральному анализу, моделированию и восстановлению сигналов [22].

Для трансформеров также появляются частотно-ориентированные архитектуры и модификации. Обзоры [23, 24] рассматривают модели, использующие преобразования Фурье, вейвлеты, дискретное косинусное преобразование и другие инструменты частотной области в задачах обработки изображений.

Для данной работы это важно как методический контекст. Частотная область уже используется в глубоких моделях, но здесь она применяется не для изменения архитектуры, а для диагностики внутренних представлений. Иными словами, работа отвечает не на вопрос «как улучшить модель», а на более узкий вопрос: как разные архитектуры перераспределяют спектральную энергию по глубине.

2.3.4 Набор данных *ImageNet* и *ImageNet 10K*

ImageNet является одним из основных наборов изображений в истории компьютерного зрения [13]. Он содержит большое число изображений и классов, а многие современные архитектуры обучаются или оцениваются именно на *ImageNet*. Поэтому этот набор данных удобен для сопоставления предобученных моделей.

В данной работе используется подвыборка *ImageNet 10K* [12]. Она содержит по 10 изображений для каждого из 1000 классов *ImageNet*. Такой набор сохраняет разнообразие классов, но остаётся вычислительно выполнимым для спектрального анализа многих моделей и промежуточных блоков.

Здесь *ImageNet 10K* используется не для обучения и не для проверки итоговой точности. Его роль другая: подать на предобученные модели одинаковые естественные изображения и сравнить их внутренние представления. Поэтому далее в работе точность (ассигасу) не рассматривается как отдельная зависимая переменная. Основной предмет исследования — спектральная организация признаков.

2.4 Выводы по теоретической главе

В этой главе введены понятия, которые нужны для методики и результатов: внутреннее представление, карта признаков, токен, патч, спектр мощности, DC-компонента, частотный радиус, круг Найквиста, радиальное среднее и радиальная энергия. Это нужно для того, чтобы дальше не смешивать разные вещи: визуальную радиальную кривую и численную долю энергии, карту признаков CNN и решётку токенов ViT, реальное изменение признаков и эффект уменьшения разрешения.

ResNet, ViT и Swin рассматриваются как три разных способа обработки пространственного сигнала. ResNet представляет свёрточную иерархию с понижением разрешения между стадиями. ViT работает с фиксированной решёткой патчевых токенов. Swin совмещает токенную обработку с иерархией и слиянием патчей. Из-за этих различий можно ожидать разные спектральные траектории по глубине.

Дальнейшая методика строится именно на этом различии. Для ResNet и Swin требуется контроль влияния понижения разрешения, потому что уменьшение разрешения само по себе сужает доступный частотный диапазон. Для ViT такой межстадийный контроль не нужен в том же виде, поскольку размер патчевой решётки сохраняется по блокам. В результатах наблюдения по графикам отделяются от возможных интерпретаций через внимание, оконную обработку или слияние патчей, так как причинные механизмы отдельно не отключались и не проверялись.

Глава 3

Методы

3.1 Спектральный анализ

Базовый протокол эксперимента был сначала реализован для ResNet18, затем адаптирован для ViT и Swin. Обобщённая процедура вычисления спектральной характеристики архитектуры приведена в алгоритме 1.

Алгоритм 1 Обобщённая процедура вычисления спектральной характеристики архитектуры

Вход: Выбранный слой нейронной сети, геометрические параметры H, W .
Выход: Нормализованная радиальная кривая спектра мощности $\tilde{E}(\rho)$.

- 1: Получить представление $\mathcal{F}$ из выбранного слоя/блока
 - 2: **if** $\mathcal{F}$ является 4D тензором (CNN) **then**
 - 3: Оставить тензор без изменений: (B, C, H, W)
 - 4: **else** $\mathcal{F}$ является 3D тензором вида (B, N, D) (ViT, Swin)
 - 5: Выполнить изменение формы в (B, H, W, D) с $H = W = \sqrt{N}$
 - 6: **end if**
 - 7: Центрировать тензор по пространству
 - 8: Выполнить 2D FFT по осям H, W для каждого канала и сдвиг центра
 - 9: Вычислить спектр мощности: $S(b, u, v, c) \leftarrow |FFT(\dots)|^2$
 - 10: Усреднить спектр по каналам: $\bar{S}_b(u, v)$
 - 11: Для каждого радиального кольца A_j вычислить среднюю мощность M_j для визуализации
 - 12: Для каждого радиального кольца A_j вычислить суммарную энергию E_j для метрик
 - 13: Нормализовать суммарную энергию: $p_j = E_j / \sum_j E_j$
 - 14: **return** $\tilde{E}(\rho)$
-

Первым этапом является процедура извлечения представлений. В данной работе «представление» — это набор значений в некотором слое модели, организованный в пространственную структуру. Спектральный анализ опирается на предположение, что эти активации можно интерпретировать как дискретную функцию на двумерной решётке.

Для каждой из исследуемых моделей были реализованы функции перехвата (hook) на выходах ключевых блоков: `layer1–layer4` для ResNet и равномерно по глубине для трансформеров ViT и Swin. На каждый такой блок подаётся один и тот же набор изображений из валидационной выборки ImageNet [12] (после стандартной нормализации). Реализация функций перехвата отличается в зависимости от используемой архитектуры, поскольку различаются представления, с которыми оперируют модели. Так, например, в ResNet каждый слой явно оперирует с двумерной картой признаков: тензоры имеют размерность (B, C, H, W) , где H и W — пространственные размеры карты признаков на данном слое, C — число каналов, B — размер батча.

ViT работает иначе: изображение разбивается на непересекающиеся патчи размера 16×16 . Каждый патч линейризуется в вектор и пропускается через линейный слой, превращаясь в токен размерности D . В результате получается последовательность токенов, длина которой составляет $N = W_{patch} \times H_{patch}$, где W_{patch} , H_{patch} — количество патчей по горизонтали и вертикали. Внутри самой модели перед первым блоком к токенам добавляются позиционные эмбеддинги; также используется CLS-токен, поэтому на вход поступает $N + 1$ токенов. Токены обрабатываются механизмом самовнимания, в котором пространственная близость не задаётся так же явно, как в свёрточной карте признаков. Поэтому на выходе блока получается не двумерная карта, а одномерная последовательность размерности $(B, N + 1, D)$ с фиксированным порядком токенов.

Чтобы провести для ViT спектральный анализ, сопоставимый с анализом CNN, в функции перехвата последовательность токенов преобразуется в двумерную карту признаков. В классификационных вариантах ViT дополнительно используется CLS-токен. Он не соответствует отдель-

ной пространственной области изображения и не является позиционным эмбедингом; его задача состоит в агрегировании информации для последующего предсказания класса. Поэтому для проведения спектрального анализа CLS-токен исключается, так как он не имеет координаты на двумерной решётке патчей. Размеры решётки патчей определяются как $H_{patch} = W_{patch} = \sqrt{N}$, поскольку после стандартной нормализации все изображения имеют квадратный размер 224×224 . Затем тензор преобразуется из формы (B, N, D) в $(B, C, H_{patch}, W_{patch})$ построчной развёрткой таким образом, что i -й токен соответствует позиции $(i \bmod W_p, \lfloor i/W_p \rfloor)$. Важно учитывать, что такая карта признаков не эквивалентна карте признаков CNN. Пространственное разрешение в ViT равно количеству патчей, а не пикселей, поскольку каждый токен соответствует неперекрывающемуся блоку пикселей и представляет его агрегированное векторное описание без явного сохранения внутренней структуры патча.

В архитектуре Swin входное изображение разбивается на непересекающиеся патчи размера 4×4 . Как и в CNN, по мере углубления модели уменьшается пространственное разрешение: между стадиями выполняется слияние патчей, которое увеличивает количество каналов и уменьшает пространственное разрешение вдвое. В Swin отсутствует CLS-токен, поэтому преобразование выполняется прямым восстановлением решётки размером $\sqrt{N} \times \sqrt{N}$. Следует отметить, что механизм сдвига окон для спектрального анализа не требует специальной дополнительной обработки, так как он уже учтён внутри блока.

Перед применением каких-либо частотных преобразований необходима предобработка. Ключевым шагом является вычитание пространственного среднего из каждой карты признаков:

$$\tilde{x}_{b,c}(h, w) = x_{b,c}(h, w) - \frac{1}{HW} \sum_{h,w} x_{b,c}(h, w) \quad (1)$$

Эта операция необходима для устранения нулевой частоты (постоянной составляющей, или DC-компоненты) из сигнала. DC-компонента представляет собой среднее значение по пространству и по абсолютной вели-

чине часто на порядки превосходит энергию остальных частот, тем самым маскируя вклад более высоких частот. Кроме того, постоянная составляющая несёт информацию, которая для целей данного исследования является скорее помехой. Её удаление необходимо, чтобы анализ был чувствительным именно к вариациям признаков, а не к их абсолютному уровню. В рамках данной работы операция выполняется независимо для каждого канала и каждого образца в батче: из каждого элемента двумерной матрицы вычитается среднее арифметическое по всем элементам этой же матрицы. Альтернативой могло бы быть высокочастотное фильтрование, но оно требует подбора граничных частот и вносит дополнительный произвол; вычитание же среднего — это простейший и в то же время строгий способ обнуления DC-компоненты без искажения остального спектра.

Для перехода из пространственной области карт признаков в частотную используется двумерное дискретное преобразование Фурье, реализуемое с помощью быстрого преобразования Фурье (БПФ). В результате получается комплекснозначный спектр $F_{b,c}(u, v)$.

$$F_{b,c}(u, v) = \sum_{h=0}^{H-1} \sum_{w=0}^{W-1} x_{b,c}(h, w) e^{-2\pi i \left(\frac{uh}{H} + \frac{vw}{W} \right)} \quad (2)$$

где $x(h, w)$ — значение признака в точке с координатами h (высота) и w (ширина), а $F(u, v)$ — комплексный коэффициент на частоте с индексами u и v . В результате для каждой карты признаков получается комплексный массив того же пространственного размера, где действительная и мнимая части кодируют амплитуду и фазу соответствующих частотных компонент. Фаза несёт информацию о пространственном расположении структур, однако в данной работе анализируется распределение энергии по низким и высоким частотам, поэтому фазовые соотношения далее не используются. На следующем этапе выполняется переход к спектру мощности.

Вычисляется спектр мощности (энергии) как квадрат модуля:

$$S_{b,c}(u, v) = |F_{b,c}(u, v)|^2 \quad (3)$$

где b — индекс изображения в батче, c — индекс канала, а (u, v)

— координаты в частотной плоскости. Энергетический спектр показывает, какой вклад вносит каждая пространственная частота в общую энергию сигнала, и инвариантен к фазе, что удобно для последующего усреднения.

На этом этапе усреднение по изображениям не выполняется. Если усреднить спектры по батчу сразу, то далее невозможно будет оценить разброс спектральных характеристик между отдельными изображениями.

$$\bar{S}_b(u, v) = \frac{1}{C} \sum_{c=1}^C S_{b,c}(u, v) \quad (4)$$

где C — число каналов на рассматриваемом слое или блоке. В результате для каждого изображения получается собственная двумерная спектральная карта $\bar{S}_b(u, v)$, которая агрегирует частотный вклад всех каналов данного представления. Важно отметить, что усреднение спектров мощности — это не то же самое, что усреднение самих карт признаков с последующим вычислением спектра. Это важно, поскольку на одних изображениях могут преобладать горизонтальные структуры, а на других — вертикальные; усреднение карт признаков привело бы к взаимному уничтожению таких разнородных признаков.

Полученный после предыдущих шагов двумерный спектр мощности $\bar{S}_b(u, v)$ содержит информацию не только о величине пространственной частоты, но и о направлении частотного вектора. Однако для целей данного исследования требуется описать, как меняется распределение энергии по мере увеличения пространственной частоты независимо от того, горизонтальная это частота, вертикальная или диагональная. Поэтому угловая зависимость далее не рассматривается, а двумерный спектр переводится в радиальное представление.

Пусть A_j — множество точек частотной плоскости, попадающих в j -е радиальное кольцо:

$$A_j = \{(u, v) : j \leq r(u, v) < j + 1\}, \quad (5)$$

где радиус частотной точки после сдвига нулевой частоты в центр спектра

определяется как

$$r(u, v) = \sqrt{(u - u_0)^2 + (v - v_0)^2}, \quad (6)$$

а (u_0, v_0) — координаты центра спектра после операции `fftshift`. Точки с близким расстоянием до центра спектра объединяются в одно кольцо, после чего двумерная частотная карта заменяется одномерным профилем по радиусу.

Поскольку размеры карт признаков и частотных плоскостей для разных слоёв модели могут различаться, прямое сравнение радиальных профилей в абсолютных единицах неудобно. Чтобы обеспечить сопоставимость спектральных характеристик слоёв с разным пространственным разрешением, вводится нормированный частотный радиус.

Максимальный радиус задаётся как

$$R_{\max} = \frac{\min(H, W)}{2}. \quad (7)$$

Такой выбор соответствует анализу частот внутри круга Найквиста по горизонтальному и вертикальному направлениям. Нормированный частотный радиус для j -го кольца определяется как

$$\rho_j = \frac{r_j}{R_{\max}}, \quad (8)$$

где r_j — радиус, соответствующий j -му радиальному кольцу.

В работе используются два близких, но не одинаковых радиальных представления. Для визуализации спектральных кривых применяется средняя мощность в кольце:

$$M_{b,j} = \frac{1}{|A_j|} \sum_{(u,v) \in A_j} \bar{S}_b(u, v). \quad (9)$$

Такой вариант удобен для графиков, потому что он показывает средний уровень спектральной мощности на данном радиусе и не делает дальние кольца визуально доминирующими только из-за большего числа точек.

Для расчёта численных метрик используется суммарная энергия коль-

ца:

$$E_{b,j} = \sum_{(u,v) \in A_j} \bar{S}_b(u,v). \quad (10)$$

Этот вариант корректен для вычисления доли энергии, потому что кольца разного радиуса содержат разное число частотных точек. Если использовать только среднее значение по кольцу, то дальние кольца будут недо-
взвешены, и такая величина уже не будет строгой долей энергии.

Однако сравнение таких функций для разных слоёв непосредственно по шкале $E(\rho)$ часто оказывается затруднительным, поскольку абсолютная энергия может существенно различаться в зависимости от глубины. Например, в глубоких слоях ResNet количество каналов растёт, а пространственное разрешение падает. Суммарная энергия карт признаков может изменяться на порядки из-за масштабирования, вносимого нормализацией, функциями активации и остаточными связями.

Для корректного сравнения слоёв с разной абсолютной энергией производится нормализация:

$$\tilde{E}_{b,j} = \frac{E_{b,j}}{\sum_j E_{b,j}}. \quad (11)$$

Величина $\tilde{E}_{b,j}$ интерпретируется как доля энергии, приходящаяся на j -й радиальный диапазон для b -го изображения. В результате получается одномерная функция $\tilde{E}_b(\rho)$, определённая на интервале $[0, 1]$ и представляющая собой нормированное распределение энергии по радиальным диапазонам. Значение $\rho = 0$ соответствует постоянной составляющей; после вычитания среднего она обнулена, поэтому значение $E(0)$ близко к нулю. Значение $\rho = 1$ соответствует границе круга Найквиста, то есть максимальной частоте, которую может нести карта признаков данного разрешения.

Сумма в знаменателе является полной энергией всех частотных компонент после удаления DC-компоненты. Нормализация превращает спектр в дискретное распределение долей энергии по частотным диапазонам. Это распределение далее используется при расчёте спектрального центроида и доли низкочастотной энергии.

У данного подхода есть важный нюанс: при нормализации теряется информация об общей энергии слоя. В работе нормализованные спектры

используются для качественного анализа формы распределения: смещения пика в сторону низких частот, островершинности или, наоборот, более плоского профиля. Для количественной оценки дополнительно вводятся метрики, которые вычисляются на основе $\tilde{E}_b(\rho)$: спектральный центроид и доля энергии в низких и высоких частотах.

Слои в ResNet и Swin имеют разное пространственное разрешение. Чтобы корректно сравнивать их спектры, применяется приведение частотной оси к единому масштабу. При сравнении кривых спектральной энергии для моделей одного семейства за эталон принимается разрешение первого слоя, и для всех остальных слоёв частотная шкала пересчитывается таким образом, чтобы физические частоты (в циклах на изображение) были сопоставимы. Это позволяет строить графики, на которых видно, как меняется распределение энергии по одним и тем же пространственным частотам по мере углубления в сеть. При входном изображении 224×224 карта признаков `layer1` имеет размер 56×56 , поэтому внутри круга Найквиста максимальный радиус равен $R_{\max}^{ref} = 28$, а число радиальных отсчётов составляет $R_{\max}^{ref} + 1 = 29$.

$$\rho_{mapped} = \rho \cdot \frac{L_{layer}}{L_{ref}}, \quad (12)$$

где L_{layer} — число радиальных отсчётов для рассматриваемого слоя, а L_{ref} — число радиальных отсчётов для эталонного уровня `layer1`.

После такого пересчёта поздние слои ResNet и Swin занимают меньший диапазон по оси частот, поскольку их пространственное разрешение ниже. Это не ошибка, а ожидаемое следствие дискретизации: у карты меньшего размера доступен меньший диапазон пространственных частот относительно исходной эталонной шкалы. Именно поэтому на графиках кривые глубоких стадий заканчиваются раньше, чем кривые начальных слоёв. Для каждого изображения метрики считаются на собственной радиальной сетке слоя после пересчёта радиуса к общему масштабу.

3.2 Метрики

Спектральный центроид

Спектральный центроид представляет собой средневзвешенную частоту, где весом выступает нормализованная энергия. Для дискретной радиальной спектральной кривой $E(\rho_k)$ центроид вычисляется как:

$$C = \frac{\sum \rho_k \cdot \tilde{E}(\rho_k)}{\sum \tilde{E}(\rho_k)} \quad (13)$$

Центроид принимает значения на отрезке $[0,1]$ и показывает, где сосредоточена основная энергия. Низкое значение центроида свидетельствует о том, что энергия представления сильнее сосредоточена в низкочастотной области - представление сглажено и содержит крупномасштабные структуры; чем выше значение, тем больше вклад средних и высоких пространственных частот - в представлении много мелких деталей, текстур и резкие границы.

Эта метрика обладает инвариантностью к масштабу, что позволяет сравнивать слои с разным пространственным разрешением и разные архитектуры. Кроме того, она чувствительна к изменениям формы спектра: даже небольшие смещения распределения энергии заметно меняют значение центроида. Поэтому центроид также удобен для вычисления скорости спектрального сжатия.

Доля энергии в низких и высоких частотах

Помимо среднего, можно численно измерить, как энергия распределена в хвостах распределения. Для этого выбирается пороговое значение τ (например, $\tau = 0.15$ для низких частот). Доля энергии в низких частотах:

$$LowFrac = \sum_{k:\rho_k < 0.15} \tilde{E}(\rho_k) \quad (14)$$

Эта метрика характеризует, какая доля спектральной энергии сосредоточена в заданном частотном диапазоне. Рост LowFrac с глубиной соответствует большей концентрации энергии в области малых частотных радиусов.

Скорость «сжатия» спектра по глубине

Также в качестве метрики можно использовать зависимость центроида от индекса слоя или относительной глубины. Далее эта характеристика называется спектральным сжатием. Спектральное сжатие – это процесс последовательного подавления высоких частот по мере углубления сети. Для его количественной оценки можно использовать линейную или экспоненциальную модель.

Для компактного описания динамики используется экспоненциальная модель: она позволяет отразить ситуацию, когда центроид быстрее меняется на ранних уровнях и затем замедляет изменение к концу сети.

$$C_i = C_0 \cdot e^{-\lambda \cdot i} \quad (15)$$

Параметры C_0 и λ подбираются методом нелинейных наименьших квадратов по значениям центроида на разных уровнях. В таблицах приводится коэффициент λ – экспоненциальная скорость затухания. Эта величина безразмерна. За один слой центроид уменьшается в $e^{-\lambda}$ раз. Если $\lambda > 0$, центроид убывает по глубине; если $\lambda \approx 0$, выраженного экспоненциального сжатия не наблюдается; если $\lambda < 0$, центроид в среднем растёт.

Другие метрики, такие как энтропия спектра или пиковая частота, не использовались, так как они менее непосредственно отвечают поставленной цели данного исследования. Энтропия спектра характеризует «размытость», но не указывает, в какую сторону смещён спектр, поэтому она более подходит для исследования устойчивости. Пиковая частота игнорирует форму распределения, не даёт информации о ширине спектра и более чувствительна к шуму.

Для оценки разброса спектральные характеристики рассчитывались отдельно для каждого изображения выборки. После этого для каждого слоя и каждой модели вычислялись среднее значение и стандартное отклонение по изображениям. На графиках стандартное отклонение отображает разброс радиального спектрального профиля между изображениями, а в таблицах — разброс соответствующей метрики по выборке. Исключение составляет коэффициент спектрального сжатия λ , поскольку он получен

из средних центроидов, а его погрешность оценивалась приближённо.

3.3 Экспериментальная постановка

Эксперименты проводились на предобученных моделях компьютерного зрения трёх семейств: ResNet, Vision Transformer и Swin Transformer. Для реализации использовались библиотеки `torch 2.10.0+cpu`, `torchvision 0.25.0+cpu`, `timm 1.0.21`, `numpy 2.1.3`. Модели семейства ResNet загружались из `torchvision.models`, а модели ViT и Swin — из библиотеки `timm`.

Для ResNet использовались модели:

`resnet18` [25], `resnet34` [26],
`resnet50` [27], `resnet101` [28].

Во всех случаях веса задавались через параметр `weights=DEFAULT`. Для `resnet18` и `resnet34` это соответствует весам `IMAGENET1K-V1`; для `resnet50` и `resnet101` — весам `IMAGENET1K-V2` в используемой версии `torchvision`.

Для ViT рассматривались модели:

`vit-tiny-patch16-224` [29], `vit-small-patch16-224` [30],
`vit-base-patch16-224` [31], `vit-large-patch16-224` [32].

Для Swin использовались:

`swin-tiny-patch4-window7-224` [33], `swin-small-patch4-window7-224` [34],
`swin-base-patch4-window7-224` [35], `swin-large-patch4-window7-224` [36].

Для моделей из `timm` использовался режим `pretrained=True`, то есть стандартные предобученные веса, заданные в конфигурации соответствующей модели.

Для ResNet анализировались выходы четырёх основных стадий: `layer1`, `layer2`, `layer3` и `layer4`. Для ViT и Swin спектры сохранялись для всех выбранных блоков, однако для основных графиков использовались пять уровней по глубине: начальный блок, блок на глубине $n/4$, средний блок, блок на глубине $3n/4$ и последний блок, где n — число блоков модели. Для итоговых таблиц метрик использовались только три уровня: начальный, средний и глубокий. Это сделано для того, чтобы таблицы оставались сопоставимыми между архитектурами.

В качестве входных данных использовалась подвыборка ImageNet 10K [12], содержащая по 10 изображений для каждого из 1000 классов ImageNet. Все изображения проходили одинаковую предобработку: изменение размера, центральное кадрирование до 224×224 , преобразование в тензор и нормализация по стандартным статистикам ImageNet: $\mu = (0.485, 0.456, 0.406)$, $\sigma = (0.229, 0.224, 0.225)$. Размер батча во всех экспериментах составлял 32.

Для оценки разброса результатов спектральные характеристики рассчитывались не только в виде одного среднего значения. Для каждого изображения строилось радиальное распределение энергии выбранного представления, после чего для каждой метрики вычислялись среднее значение и стандартное отклонение по выборке:

$$\overline{M} = \frac{1}{N} \sum_{i=1}^N M_i, \quad (16)$$

$$\sigma_M = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (M_i - \overline{M})^2}, \quad (17)$$

где M_i — значение метрики для i -го изображения, а N — число изображений, участвующих в расчёте. В таблицах значения приводятся в формате $\overline{M} \pm \sigma_M$. На графиках погрешность отображается через область стандартного отклонения вокруг средней спектральной кривой либо через интервалы погрешности, если график строится по отдельным значениям метрик.

Отдельно проводились контрольные эксперименты для ResNet и Swin. Их задача состояла в том, чтобы отделить изменение спектрального профиля представлений от тривиального эффекта уменьшения пространственного разрешения. В ResNet пространственный размер карт признаков уменьшается при переходе между стадиями, а в Swin аналогичную роль играет операция слияния патчей. Поэтому наблюдаемое смещение спектра к низким частотам нельзя автоматически считать свойством только обученных признаков.

Первый контрольный эксперимент представляет собой базовый контрольный вариант на основе снижения разрешения. В нём раннее пред-

ставление модели искусственно приводится к разрешению более глубокого уровня с помощью операции уменьшения разрешения, после чего для него рассчитываются те же спектральные метрики. Для ResNet сравниваются реальные `layer2`, `layer3`, `layer4` и представление `layer1`, искусственно приведённое к тем же пространственным размерам. Для Swin аналогично сравниваются реальные поздние стадии и раннее представление, приведённое к их разрешению. Если реальные глубокие представления близки к такой базовой модели, то низкочастотное смещение в основном объясняется снижением разрешения. Если же реальные представления дополнительно смещены к низким частотам, значит, часть эффекта связана уже с изменением самих признаков. Искусственное уменьшение разрешения в контрольных экспериментах выполнялось с помощью адаптивного среднего пулинга. В реализации использовалась функция `torch.nn.functional.adaptive_avg_pool2d`, где выходной размер задавался равным пространственному размеру соответствующего глубокого слоя. Для ResNet исходным представлением служил `layer1`, который приводился к размерам `layer2`, `layer3` и `layer4`. Для Swin аналогично использовалось начальное представление первой стадии, приводимое к разрешениям последующих стадий. Такой оператор выбран как простая необучаемая базовая процедура понижения разрешения. При этом сам средний пулинг подавляет часть высокочастотных компонент, поэтому контроль следует интерпретировать как базовую модель влияния уменьшения разрешения, а не как полное воспроизведение внутренних операций ResNet или Swin.

Второй контрольный эксперимент — внутретадийное сравнение. В нём сравниваются блоки, имеющие одинаковое пространственное разрешение. Для ResNet такой контроль выполняется внутри одной стадии, например внутри `layer3` в ResNet50. Для Swin сравниваются блоки внутри одного этапа. Если спектральные метрики меняются при фиксированном размере карты или решётки, то этот эффект уже нельзя объяснить одним только уменьшением разрешения.

Для ViT отдельный контроль понижения разрешения между блоками не требуется в том же виде, что для ResNet и Swin, поскольку стан-

дартный ViT сохраняет одну и ту же решётку патчевых токенов по всей глубине модели. Поэтому для ViT дополнительно фиксируется, что пространственный размер токеной решётки остаётся постоянным, а наблюдаемые изменения спектра между блоками не связаны с межстадийным уменьшением разрешения.

Глава 4

Результаты

В этой главе приведены результаты спектрального анализа промежуточных представлений моделей ResNet, ViT и Swin. В главе отдельно рассматриваются два типа материалов: радиальные спектральные кривые и сводные численные метрики, рассчитанные по этим кривым. Такой порядок позволяет сначала проанализировать форму спектра визуально, а затем проверить те же наблюдения через центроид, долю низкочастотной энергии и скорость спектрального сжатия.

Для визуализации берётся средняя мощность в кольце, затем каждая кривая нормируется на свой максимум для сравнимости формы. Поэтому по ним сравнивается не абсолютная величина энергии, а форма радиального распределения. Полупрозрачные области вокруг линий показывают разброс значений по изображениям выборки. Для численных таблиц ниже используются уже не радиальные средние значения, а суммарная энергия по кольцам; это важно, потому что только так доля низкочастотной энергии действительно учитывает число точек в каждом радиальном диапазоне.

4.1 Спектральные кривые

4.1.1 Динамика внутри ResNet

На Рис. 1 показано, как меняется радиальный спектр мощности при переходе от `layer1` к `layer4` в ResNet18. Здесь хорошо видна характерная для свёрточной сети картина: ранний уровень даёт более широкий спектр,

а поздние уровни постепенно стягивают энергию к области малых частотных радиусов. У `layer1` хвост кривой длиннее. Это значит, что в представлении ещё остаётся заметная доля средне- и высокочастотных компонент, которые могут соответствовать границам, текстурам и мелким локальным изменениям.

Дальше спектр становится уже. На `layer2` и `layer3` вклад более высоких частот уменьшается, а на `layer4` кривая занимает уже ограниченный участок частотной оси. По сути, слой всё меньше похож на представление с большим количеством локальных деталей и всё больше — на сглаженное описание крупных структур. Но здесь нужно быть аккуратным: в ResNet при переходе между стадиями уменьшается пространственное разрешение. Значит, часть сужения спектра может быть обычным следствием понижения разрешения, а не только свойством обученных признаков.

ResNet18 на этом графике даёт удобный базовый пример низкочастотной динамики в свёрточной сети. Ранние карты признаков сохраняют широкий частотный диапазон, поздние — переходят к более узкому описанию. Доказательность этого вывода проверяется ниже через контрольный эксперимент: реальный глубокий слой сравнивается с ранним слоем, искусственно приведённым к тому же пространственному размеру.

На Рис. 2 приведён контрольный эксперимент для ResNet18. Сравниваются реальный `layer4` и представление `layer1`, искусственно уменьшенное до размера `layer4`. Если бы наблюдаемое сужение спектра объяснялось только уменьшением разрешения, эти две кривые должны были бы быть близки.

На графике видно другое. Искусственно уменьшенный `layer1` сохраняет более высокий хвост в правой части частотного диапазона. Реальный `layer4` после низкочастотного пика падает заметно резче и почти не сохраняет энергии в более высоких радиусах. Таким образом, это главный контроль для ResNet: одно только уменьшение пространственного размера не воспроизводит форму глубокого слоя. Значит, в ResNet есть дополнительное изменение спектрального профиля сверх простого понижения разрешения.




Рис. 1. Изменение спектрального профиля по слоям ResNet18.

На Рис. 3 показан второй контроль — сравнение блоков внутри `layer3` модели ResNet50. Эти блоки имеют одинаковое пространственное разрешение, поэтому различия между ними уже нельзя объяснить переходом к меньшей карте признаков.

Кривые внутри стадии очень близки. Небольшие отличия есть, но они намного слабее, чем различия между `layer1`, `layer2`, `layer3` и `layer4`. Это уточняет вывод: наиболее резкая часть спектральной динамики ResNet связана именно с межстадийными переходами и накопленным изменением признаков. Внутри одной стадии при фиксированном разрешении спектр меняется гораздо спокойнее.

4.1.2 Динамика внутри ViT

На Рис. 4 приведены спектральные кривые выбранных блоков ViT-Large. По сравнению с ResNet поведение здесь другое. Не видно простого движения, при котором каждый следующий блок всё сильнее сжимает спектр к низким частотам. Напротив, поздние блоки ViT-Large сохраняют более заметный вклад в области средних частот. Особенно хорошо это




Рис. 2. Контроль влияния понижения разрешения для ResNet18: сравнение реального `layer4` и `layer1`, приведённого к размеру `layer4`.

видно по `block_17` и `block_23`: спад у них более пологий, а хвост остаётся выше, чем у ранних блоков.

Это наблюдение методически удобно: в стандартном ViT размер патчевой решётки не уменьшается от блока к блоку. Поэтому изменения между блоками нельзя списать на межстадийное понижение разрешения, как это приходится делать для ResNet и Swin. Здесь мы видим именно изменение токенных представлений на фиксированной пространственной решётке.

При этом более широкий хвост не стоит читать как прямое доказательство лучшего сохранения полезной семантики. График говорит о другом: в выбранном протоколе ViT-Large не демонстрирует устойчивого низкочастотного сжатия. Что именно несёт энергия в среднечастотной области — полезные детали, особенности токенового кодирования или побочные вариации, — требует отдельного анализа. В данной работе фиксируется сам факт: динамика ViT не похожа на последовательное подавление более высоких частот.




Рис. 3. Внутретадийный контроль для ResNet50: спектральные профили блоков внутри `layer3` при фиксированном пространственном разрешении.

4.1.3 Динамика внутри Swin

На Рис. 5 показана динамика выбранных блоков Swin-Large. Начальный блок `stage0_block0` имеет резкий низкочастотный пик и быстро убывающий хвост. Далее картина становится менее прямой: на блоках `stage2` часть кривых расширяется и сохраняет заметную энергию в среднечастотной зоне. Финальный `stage3_block1` снова расположен в более узком диапазоне.

Swin, таким образом, не повторяет ResNet один к одному. У него есть иерархическая структура и операция объединения патчей, но средние стадии ведут себя сложнее. Возможное объяснение связано с оконной обработкой и изменением локальных взаимодействий между токенами. Однако это именно интерпретация, а не отдельный причинный эксперимент. Поэтому дальше я проверяю, насколько финальное сужение Swin можно объяснить одним только уменьшением разрешения.

На Рис. 6 приведён контроль понижения разрешения для Swin-Base. Сравниваются реальный финальный блок и начальное представление, ис-




Рис. 4. Изменение спектрального профиля по блокам ViT-Large.

кусственно приведённое к размеру финальной стадии. Этот контроль нужен, потому что в Swin уменьшение разрешения выполняется через **слияние патчей**, и оно само по себе способно сделать спектр более низкочастотным.

Основной пик у двух кривых близок. Значит, уменьшение разрешения действительно объясняет заметную часть финального низкочастотного профиля Swin. Но полного совпадения нет: в хвосте спектра реальная кривая и базовая расходятся. Поэтому вывод по Swin должен быть осторожнее, чем по ResNet. Swin приходит к низкочастотному финальному состоянию, но существенная часть этого эффекта связана с архитектурным уменьшением решётки.

4.1.4 Количественная проверка контрольных экспериментов

Приведённые выше контрольные графики требуют численного уточнения, поскольку визуальное сравнение нормированных кривых показывает только форму спектра. Для этой цели были сопоставлены значения спектрального центроида и доли низкочастотной энергии у реальных представлений и у контрольных представлений, полученных искусственным по-



Рис. 5. Изменение спектрального профиля по блокам Swin-Large.

нижением пространственного разрешения. Такой контроль позволяет проверить, объясняется ли наблюдаемое сужение спектра только уменьшением размера карты признаков.

Для ViT дополнительный контроль пространственного разрешения показывает, что во всех рассмотренных вариантах модели — Tiny, Small, Base и Large — выбранные блоки имеют одинаковую решётку 14×14 , а длина радиального профиля равна 8. Следовательно, сравнение блоков ViT по глубине не смешивается с изменением пространственного разрешения. Поэтому немонотонная динамика центроида и доли низкочастотной энергии для ViT относится именно к изменению внутренних представлений на фиксированной решётке патчей.

Таб. 1 показывает, что для ResNet18 реальные представления имеют меньший центроид, чем контрольные представления, полученные простым понижением разрешения. Разность центроида составляет -0.016 для `layer2`, -0.013 для `layer3` и -0.020 для `layer4`. Наиболее показателен `layer3`: доля низкочастотной энергии в реальном представлении выше контрольного значения на 9.903 процентного пункта. Это означает, что в ResNet18




Рис. 6. Контроль влияния понижения разрешения для Swin-Base: сравнение реального финального блока и начального представления, приведённого к размеру последней стадии.

сдвиг к низким частотам не сводится к изменению пространственного размера карты признаков.

Для Swin-Base картина отличается. На первых двух стадиях реальные представления имеют больший центроид и меньшую долю низкочастотной энергии, чем контрольные представления. На `stage1_block0` разность центроида равна $+0.086$, а доля низкочастотной энергии ниже контрольного значения на 27.666 процентного пункта. На `stage2_block0` соответствующие различия составляют $+0.038$ и -22.485 процентного пункта. На третьей стадии разница незначительна и лежит в пределах стандартного отклонения. Следовательно, само понижение разрешения в Swin-Base создаёт более выраженный низкочастотный сдвиг, чем реальные преобразования ранних стадий. Это уточняет интерпретацию Swin: финальный низкочастотный профиль связан с иерархическим уменьшением решётки, но внутренние преобразования модели частично сохраняют средне- и высокочастотные компоненты.

Таблица 1. Контроль влияния понижения пространственного разрешения на спектральные метрики

Модель	Уровень	Центроид	Контроль	Δ	Низкие частоты, %	Контроль, %	Δ , п.п.
ResNet18	layer2	0.235 ± 0.014	0.251 ± 0.019	-0.016	34.694 ± 4.775	32.342 ± 5.919	+2.352
	layer3	0.119 ± 0.006	0.132 ± 0.010	-0.013	64.038 ± 3.533	54.135 ± 6.241	+9.903
	layer4	0.055 ± 0.002	0.074 ± 0.005	-0.020	100.000 ± 0.000	100.000 ± 0.000	0.000
Swin-Base	stage1_block0	0.242 ± 0.022	0.155 ± 0.037	+0.086	37.006 ± 6.905	64.672 ± 11.936	-27.666
	stage2_block0	0.130 ± 0.009	0.092 ± 0.016	+0.038	54.939 ± 5.443	77.424 ± 8.472	-22.485
	stage3_block0	0.075 ± 0.007	0.067 ± 0.008	+0.008	100.000 ± 0.000	100.000 ± 0.000	0.000

Таблица 2. Внутретадийный контроль при фиксированном пространственном разрешении

Модель	Положение	Блок	Центроид	Низкие частоты, %	Высокие частоты, %
ResNet50, layer3	начальный	layer3_block0	0.462 ± 0.024	21.431 ± 4.341	43.100 ± 4.114
	средний	layer3_block3	0.438 ± 0.023	23.053 ± 3.876	38.308 ± 3.918
	глубокий	layer3_block5	0.435 ± 0.021	23.117 ± 3.403	37.452 ± 3.640
Swin-Base, stage2	начальный	stage2_block0	0.471 ± 0.033	22.578 ± 5.910	45.061 ± 5.443
	средний	stage2_block9	0.604 ± 0.014	7.497 ± 1.583	69.731 ± 3.508
	глубокий	stage2_block17	0.391 ± 0.051	26.830 ± 6.676	28.748 ± 9.955

Таб. 2 дополняет предыдущий контроль, поскольку в ней сравниваются блоки внутри одной стадии, то есть при фиксированном пространственном разрешении. Для ResNet50 внутри layer3 наблюдается умеренное снижение центроида с 0.462 ± 0.024 до 0.435 ± 0.021 и уменьшение доли высокочастотной энергии с $43.100 \pm 4.114\%$ до $37.452 \pm 3.640\%$. Эти изменения слабее межстадийных различий, но они показывают, что спектральное сжатие в ResNet присутствует и внутри стадии.

Для Swin-Base внутри stage2 динамика оказывается немонотонной. Средний блок имеет больший центроид, чем начальный: 0.604 ± 0.014 против 0.471 ± 0.033 , а доля высокочастотной энергии возрастает с $45.061 \pm 5.443\%$ до $69.731 \pm 3.508\%$. В глубоком блоке центроид снижается до 0.391 ± 0.051 , а доля высокочастотной энергии уменьшается до $28.748 \pm 9.955\%$. Следовательно, внутри одной стадии Swin-Base не демонстрирует простого последовательного сжатия спектра: сначала происходит усиление более высокочастотной составляющей, а затем выраженный сдвиг к низким частотам.

В совокупности контрольные эксперименты показывают, что наблюдаемая спектральная динамика не является только следствием изменения

пространственного разрешения. Для ResNet низкочастотный сдвиг усиливается внутренними преобразованиями сети, для ViT сравнение выполняется на фиксированной решётке патчей, а для Swin влияние понижения разрешения и внутренних преобразований имеет различный характер на разных стадиях.

4.1.5 Межсемейственное сравнение архитектур

На Рис. 7 показаны нормализованные радиальные спектры мощности для начальных уровней ResNet, ViT и Swin. У всех семейств максимум находится в области малых частотных радиусов. Значит, уже в начале обработки основная энергия признаков сосредоточена около низких частот.

При этом кривые не совпадают. У ResNet хвост после основного пика выглядит более протяжённым: начальные свёрточные признаки ещё несут часть локальной текстурной информации. У ViT и Swin начальные представления формируются не как плотные пиксельные карты признаков, а через патчи и токены. Поэтому их спектральный профиль задаётся другой пространственной дискретизацией. На этом уровне различия между архитектурами ещё не максимальны, но видно, что каждая из них стартует с собственной формой распределения энергии.

На средних уровнях различия становятся заметнее (Рис. 8). ResNet быстрее смещается к низкочастотной области: после пика энергия падает достаточно резко. ViT и Swin ведут себя менее однородно. У части кривых сохраняется более высокий хвост в среднечастотной области, а у некоторых моделей видны локальные подъёмы в правой части рассматриваемого диапазона.

Этот график полезен тем, что показывает не только «кто шире», но и насколько по-разному устроена середина моделей. ResNet к этому моменту уже в значительной степени агрегирует признаки. ViT сохраняет более свободную динамику на фиксированной решётке патчей. Swin находится между ними: он иерархичен, но на средних стадиях не выглядит полностью свёрточным.

На Рис. 9 сравниваются последние уровни моделей. ResNet имеет




Рис. 7. Сравнение радиальных спектров мощности начальных уровней ResNet, ViT и Swin.

наиболее узкий финальный профиль: после основного пика энергия быстро падает, а хвост остаётся небольшим. ViT показывает более неоднородную картину. У части моделей финальный спектр остаётся достаточно широким, особенно у крупных вариантов. Swin, по форме, занимает промежуточное положение: финальные кривые уже ограничены по частотному диапазону, но не совпадают полностью с ResNet.

На графиках у некоторых кривых виден небольшой подъём хвоста у правой границы. Это не нужно интерпретировать как содержательное усиление самых высоких частот. Такой эффект связан с обработкой частотной плоскости внутри круга Найквиста и с тем, что в крайних радиальных кольцах остаётся меньше точек, а нормировка кривых по максимуму делает малые колебания более заметными. На численные выводы это влияет слабо: метрики рассчитываются по суммарной энергии кольца, а не только по визуальной форме нормированной кривой. Поэтому правый край графика в этой работе используется осторожно; основной смысл несут положение центроида, доля энергии в низких частотах и общая форма спада




Рис. 8. Сравнение радиальных спектров мощности средних уровней ResNet, ViT и Swin.

после пика.

По графикам видно, что трансформерные архитектуры не повторяют спектральную динамику CNN. ResNet даёт наиболее последовательное сжатие спектра, ViT показывает более свободное перераспределение энергии, а Swin оказывается между ними. Но после контрольных экспериментов этот вывод звучит точнее: для ResNet и Swin часть сужения связана с уменьшением пространственного разрешения, тогда как для ViT такая причина между блоками отсутствует.

4.2 Сводная интерпретация по метрикам

Для численного сравнения использовались три показателя: спектральный центроид, доля низкочастотной энергии и скорость спектрального сжатия. Графики дают форму кривой, а метрики позволяют проверить те же наблюдения в компактном виде. Значения в таблицах приведены в формате среднее $\pm$ стандартное отклонение по изображениям выборки.

В Таб. 3 приведены значения спектрального центроида для моделей




Рис. 9. Сравнение радиальных спектров мощности последних уровней ResNet, ViT и Swin.

разных семейств. У ResNet картина самая ровная: центроид уменьшается от начальных уровней к глубоким во всех четырёх моделях. Для ResNet18 он снижается с 0.431 ± 0.034 до 0.055 ± 0.002 , для ResNet34 — с 0.436 ± 0.036 до 0.056 ± 0.002 , для ResNet50 — с 0.480 ± 0.034 до 0.071 ± 0.004 , для ResNet101 — с 0.484 ± 0.032 до 0.067 ± 0.004 . Это численно подтверждает то, что было видно на графиках: по глубине ResNet сдвигает энергию к меньшим частотным радиусам.

Есть и небольшая деталь. У ResNet50 и ResNet101 начальный центроид выше, чем у ResNet18/34. Возможно, это связано с более широкой и сложной структурой bottleneck-блоков. Но к финальным уровням все модели приходят к близкому диапазону. Значит, более глубокая ResNet меняет траекторию сжатия, но итоговый низкочастотный характер остаётся общим для всего семейства.

У ViT значения центроида лежат в более узком диапазоне, но ведут себя менее регулярно по глубине. У Tiny центроид практически возвращается к начальному уровню: 0.120 ± 0.011 в начале и 0.121 ± 0.004 на

Таблица 3. Спектральный центроид различных архитектур

Архитектура	Тип	Начальные	Средние	Глубокие
CNN	resnet18	0.431 ± 0.034	0.119 ± 0.006	0.055 ± 0.002
	resnet34	0.436 ± 0.036	0.123 ± 0.006	0.056 ± 0.002
	resnet50	0.480 ± 0.034	0.120 ± 0.006	0.071 ± 0.004
	resnet101	0.484 ± 0.032	0.114 ± 0.005	0.067 ± 0.004
ViT	Tiny	0.120 ± 0.011	0.112 ± 0.010	0.121 ± 0.004
	Small	0.125 ± 0.011	0.149 ± 0.013	0.134 ± 0.011
	Base	0.112 ± 0.008	0.133 ± 0.012	0.117 ± 0.013
	Large	0.121 ± 0.007	0.143 ± 0.007	0.154 ± 0.007
Swin	Tiny	0.369 ± 0.086	0.124 ± 0.007	0.075 ± 0.006
	Small	0.348 ± 0.091	0.156 ± 0.005	0.072 ± 0.007
	Base	0.340 ± 0.090	0.154 ± 0.004	0.078 ± 0.010
	Large	0.383 ± 0.079	0.167 ± 0.004	0.073 ± 0.007

глубоком блоке. У Small и Base максимум приходится на средний уровень. У Large центроид растёт от 0.121 ± 0.007 до 0.154 ± 0.007 . Такая динамика не похожа на устойчивое подавление средних частот. Скорее ViT перераспределяет энергию между блоками, а не просто сжимает её к низкочастотной области.

У Swin центроид заметно снижается к глубоким блокам: финальные значения лежат в диапазоне 0.072–0.078. При этом средний уровень у Swin ведёт себя не полностью одинаково для всех масштабов: у Tiny центроид ниже, чем у Small/Base/Large. Это согласуется с графиками: Swin действительно приходит к низкочастотному финальному состоянию, но промежуточная динамика у него сложнее, чем у ResNet, и сильнее зависит от стадии.

В Таб. 4 приведена доля низкочастотной энергии при пороге $\rho < 0.15$. Для CNN эта метрика растёт во всех моделях. У ResNet18 значение увеличивается с 17.832 ± 4.562 до 100.000 ± 0.000 , у ResNet34 — с 19.230 ± 4.878 до 100.000 ± 0.000 , у ResNet50 — с 16.692 ± 4.354 до 100.000 ± 0.000 , у ResNet101 — с 16.051 ± 4.066 до 100.000 ± 0.000 . Здесь центроид и доля низких частот дают согласованную картину: спектр ResNet по глубине

сжимается, а низкочастотная область получает всё больший вес.

При этом значение 100% на глубоких уровнях не надо понимать как «вся информация стала низкочастотной» в содержательном смысле. Оно возникает потому, что после приведения частотной оси к масштабу `layer1` доступный диапазон глубоких карт ResNet полностью попадает ниже выбранного порога $\rho < 0.15$. Поэтому эта метрика здесь одновременно отражает и спектральную концентрацию, и эффект уменьшения пространственного разрешения. Именно поэтому выше был добавлен контроль понижения разрешения.

Таблица 4. Доля низкочастотной энергии различных архитектур, %

Архитектура	Тип	Начальные	Средние	Глубокие
CNN	resnet18	17.832 ± 4.562	64.038 ± 3.533	100.000 ± 0.000
	resnet34	19.230 ± 4.878	60.876 ± 3.543	100.000 ± 0.000
	resnet50	16.692 ± 4.354	62.548 ± 3.640	100.000 ± 0.000
	resnet101	16.051 ± 4.066	67.072 ± 3.017	100.000 ± 0.000
ViT	Tiny	61.314 ± 6.542	65.695 ± 5.778	62.119 ± 3.112
	Small	58.272 ± 6.399	43.058 ± 8.355	51.924 ± 6.795
	Base	68.402 ± 4.884	52.567 ± 7.525	62.402 ± 7.364
	Large	62.201 ± 4.225	46.683 ± 4.687	39.819 ± 4.989
Swin	Tiny	39.189 ± 13.636	59.380 ± 4.247	100.000 ± 0.000
	Small	43.009 ± 14.656	37.743 ± 3.771	100.000 ± 0.000
	Base	44.194 ± 14.614	38.511 ± 3.146	100.000 ± 0.000
	Large	36.661 ± 12.507	28.543 ± 3.607	100.000 ± 0.000

У ViT единой траектории нет. У Tiny доля низкочастотной энергии остаётся примерно на одном уровне: 61.314 ± 6.542 в начале и 62.119 ± 3.112 на глубоком блоке. У Small и Base видно снижение на среднем уровне и частичное восстановление к глубокому. У Large доля низких частот падает почти последовательно — с 62.201 ± 4.225 до 39.819 ± 4.989 . Это ещё раз показывает: ViT нельзя описать одной простой схемой низкочастотного накопления.

У Swin доля низких частот к глубоким блокам также доходит до 100% при выбранном пороге. Здесь причина похожа на ResNet: финаль-

ная стадия имеет меньшую решётку, и после приведения к масштабу начального уровня доступные радиусы оказываются внутри низкочастотного диапазона. Поэтому вывод по Swin нельзя делать только по этой таблице. Нужно совместно учитывать центроид, форму кривых и контроль понижения разрешения.

Таб. 5 показывает скорость спектрального сжатия в экспоненциальной модели (Уравнение 15) У CNN значения λ наиболее высокие: от 1.930 до 2.028. Это согласуется с графиками и таблицей центроидов: ResNet демонстрирует наиболее выраженное снижение спектрального центроида по глубине. При этом разброс значений относительно небольшой, то есть такой режим характерен для всех рассмотренных моделей семейства.

У ViT коэффициент близок к нулю или отрицателен. Для Tiny он равен -0.103 ± 0.132 , то есть почти не отличается от нуля с учётом погрешности. Для Large значение составляет -0.334 ± 0.078 , что уже указывает на рост центроида по глубине. Поэтому ViT нельзя описывать как архитектуру с экспоненциальным низкочастотным сжатием: в данном эксперименте его спектральная динамика остаётся немонотонной.

У Swin значения λ положительные и лежат в диапазоне от 0.951 до 1.774. По этой метрике Swin оказывается ближе к ResNet, чем к ViT: центроид у него в среднем снижается по глубине. Однако этот результат нужно читать вместе с контрольным экспериментом, поскольку часть снижения у Swin связана с уменьшением пространственной решётки через **слияние** патчей.

Таблица 5. Коэффициент экспоненциального спектрального сжатия λ

Архитектура	Tiny(18)	Small(34)	Base(50)	Large(101)
CNN	1.930 ± 0.109	1.954 ± 0.115	2.019 ± 0.098	2.028 ± 0.085
ViT	-0.103 ± 0.132	-0.206 ± 0.115	-0.078 ± 0.112	-0.334 ± 0.078
Swin	1.774 ± 0.426	1.063 ± 0.365	0.951 ± 0.353	1.171 ± 0.312

Сопоставление трёх таблиц даёт общий вывод по метрикам. ResNet демонстрирует наиболее устойчивое снижение центроида и рост низкочастотной доли. ViT показывает немонотонную динамику: коэффициент λ

у него близок к нулю или отрицателен, поэтому модель нельзя описать как архитектуру с последовательным экспоненциальным сжатием спектра. Swin по значениям λ занимает промежуточное положение: снижение центроида выражено достаточно заметно, но контроль понижения разрешения показывает, что для него особенно важен вклад уменьшения пространственного разрешения.

4.3 Обобщение экспериментальных результатов

Совместный анализ графиков и таблиц показывает, что архитектуры различаются не только числом параметров. Они по-разному меняют частотный состав внутренних представлений. Это видно уже на уровне спектральных кривых, а затем подтверждается центроидом, долей низких частот и скоростью сжатия.

Для ResNet наблюдается самый понятный сценарий. Центроид падает, доля низкочастотной энергии растёт, скорость сжатия положительна во всех вариантах. Однако теперь этот вывод нужно формулировать точнее: часть низкочастотного сдвига связана с уменьшением пространственного разрешения между стадиями. Контрольный эксперимент показывает, что понижение разрешения не объясняет всё полностью, потому что реальный `layer4` заметно уже, чем искусственно уменьшенный `layer1`. Поэтому для ResNet корректнее говорить о совместном эффекте архитектурной иерархии и изменения самих признаков.

ViT ведёт себя иначе. Его центроид может расти на средних или поздних блоках, а доля низких частот меняется без единого шаблона. Это не является локальным исключением: изображение обрабатывается как последовательность патчей, и блоки модели не обязаны давать монотонное спектральное сжатие. При этом в работе не утверждается, что причина связана только с механизмом внимания. По данным эксперимента можно сказать более строго: при фиксированной патчевой решётке ViT перераспределяет спектральную энергию немонотонно.

Swin занимает промежуточное место. На глубоких блоках он приходит к низким значениям центроида и высокой доле низкочастотной энер-

гии, то есть финально сближается с CNN. Но контроль понижения разрешения показывает, что значительная часть этого сближения связана с уменьшением решётки через **слияние патчей**. При этом графики средних стадий говорят, что Swin всё же не является простой копией ResNet: внутри сети есть участки с более широким спектральным профилем.

Главный экспериментальный результат можно сформулировать так: ResNet даёт наиболее последовательное низкочастотное сжатие, ViT — немонотонное перераспределение спектральной энергии при фиксированной решётке патчей, Swin — финальный низкочастотный профиль, который частично объясняется понижением разрешения. Архитектура задаёт не только конечную форму представления, но и сам путь перераспределения энергии по глубине.

Глава 5

Заключение

В работе были рассмотрены спектральные характеристики внутренних представлений трёх семейств моделей компьютерного зрения: ResNet, ViT и Swin. Основной интерес состоял не в анализе итогового класса, предсказываемого моделью, а в изменении частотной структуры признаков внутри модели. Цель состояла в том, чтобы определить, по-разному ли архитектуры перераспределяют энергию между низкими, средними и более высокими пространственными частотами.

Для этого был собран единый протокол спектрального анализа. В ResNet анализировались карты признаков основных стадий. В ViT последовательность патчевых токенов переводилась обратно в двумерную решётку, при этом CLS-токен исключался, так как он не соответствует отдельной пространственной позиции. В Swin учитывалась стадийная структура модели и изменение размера токеновой решётки между уровнями. После получения представлений строился спектр мощности, затем выполнялся переход к радиальному описанию. Для графиков использовалась средняя мощность в радиальном кольце, а для численных метрик — суммарная энергия кольца. Это различие важно: именно суммарная энергия позволяет корректно считать долю низкочастотной энергии, поскольку радиальные кольца содержат разное число точек.

Отдельно была уточнена методика сравнения частотных радиусов. Частотная ось приводилась к общему масштабу, связанному с начальным слоем ResNet, а расчёт выполнялся внутри круга Найквиста. Из-за этого на части графиков у правой границы появляется небольшой подъём хвоста.

В работе он не интерпретируется как содержательное усиление высоких частот. Это является визуальным артефактом радиального представления и нормировки кривых по максимуму. Численные выводы при этом опираются не на край графика, а на центроид, долю энергии в низкочастотной области и коэффициент экспоненциального сжатия.

Первое рабочее предположение относилось к свёрточным сетям. Ожидалось, что ResNet по мере перехода к глубоким стадиям будет смещать спектр представлений к меньшим частотным радиусам. Это предположение в целом подтвердилось. Во всех рассмотренных ResNet спектральный центроид снижается от начальных уровней к глубоким: у ResNet18 — с 0.431 ± 0.034 до 0.055 ± 0.002 , у ResNet34 — с 0.436 ± 0.036 до 0.056 ± 0.002 , у ResNet50 — с 0.480 ± 0.034 до 0.071 ± 0.004 , у ResNet101 — с 0.484 ± 0.032 до 0.067 ± 0.004 . Доля низкочастотной энергии также растёт: на глубоких уровнях она достигает 100% при выбранном пороге $\rho < 0.15$. Это значение не означает, что вся содержательная структура стала «низкочастотной» в обычном смысле. Оно связано ещё и с тем, что после приведения частотной оси к масштабу `layer1` доступный радиальный диапазон глубоких карт целиком попадает ниже выбранного порога.

Коэффициент экспоненциального спектрального сжатия у ResNet оказался самым высоким среди трёх семейств: от 1.930 ± 0.109 до 2.028 ± 0.085 . Иными словами, по таблицам ResNet действительно демонстрирует наиболее устойчивое снижение центроида по глубине. Но здесь есть важное уточнение. Контрольный эксперимент показал, что сужение спектра нельзя полностью свести к обычному уменьшению пространственного разрешения. Реальный `layer4` ResNet18 оказался заметно уже, чем `layer1`, искусственно приведённый к размеру `layer4`. Следовательно, в ResNet есть эффект сверх простого понижения разрешения. При этом внутростадийный контроль ResNet50 показал, что внутри `layer3`, где пространственное разрешение фиксировано, кривые меняются гораздо спокойнее. Поэтому корректная формулировка такая: низкочастотная динамика ResNet возникает как совместный результат архитектурной иерархии и изменения самих признаков.

Второе предположение касалось ViT. Здесь ожидалось, что трансформер не обязан повторять поведение CNN, потому что он работает с последовательностью патчевых токенов и сохраняет одну и ту же патчевую решётку по глубине. Результаты это подтвердили. У ViT нет устойчивого экспоненциального сжатия спектра. У Tiny центроид почти возвращается к начальному значению: 0.120 ± 0.011 в начале и 0.121 ± 0.004 на глубоком блоке. У Small и Base максимум центроида приходится на средний уровень. У Large центроид растёт с 0.121 ± 0.007 до 0.154 ± 0.007 .

Доля низкочастотной энергии у ViT также не даёт единой монотонной картины. У Tiny она остаётся примерно на одном уровне, у Small и Base снижается на среднем уровне и затем частично восстанавливается, а у Large падает с $62.201 \pm 4.225\%$ до $39.819 \pm 4.989\%$. Коэффициент λ у ViT близок к нулю или отрицателен: от -0.103 ± 0.132 у Tiny до -0.334 ± 0.078 у Large. По этим числам ViT нельзя описать как архитектуру с последовательным низкочастотным сжатием. Более точный вывод звучит иначе: при фиксированной патчевой решётке ViT немонотонно перераспределяет спектральную энергию между блоками.

Важно не делать из этого лишних причинных выводов. Более широкий хвост у поздних блоков ViT не доказывает сам по себе, что модель «лучше сохраняет полезные детали». Графики показывают форму спектрального распределения, а не полезность конкретных частот для решения задачи. Возможные объяснения через механизм внимания, остаточные связи или MLP-блоки выглядят правдоподобно, но в этой работе они не проверялись отдельными абляционными экспериментами. Поэтому в выводе фиксируется наблюдение, а не причинная схема.

Третье предположение относилось к Swin. Предполагалось, что из-за иерархической структуры и операций объединения патчей Swin будет ближе к CNN на глубоких стадиях, но при этом его промежуточная динамика может отличаться от ResNet. Эта гипотеза подтвердилась с оговоркой. У Swin центроид к глубоким блокам заметно снижается: финальные значения лежат в диапазоне 0.072–0.078. Доля низкочастотной энергии на глубоких уровнях также достигает 100% при выбранном пороге. Коэффициент λ по-

ложителен и находится в диапазоне от 0.951 ± 0.353 до 1.774 ± 0.426 . По этим числам Swin ближе к ResNet, чем к ViT.

При этом контроль понижения разрешения уточняет вывод. В Swin значительная часть финального низкочастотного профиля объясняется уменьшением токеной решётки через **слияние патчей**. Реальная кривая и искусственно уменьшенное начальное представление не совпадают полностью, но основной низкочастотный пик у них близок. Поэтому нельзя утверждать, что всё финальное сжатие Swin вызвано только изменением признаков внутри трансформерных блоков. Таким образом, Swin занимает промежуточное положение: на финальных уровнях он приходит к низкочастотному профилю, но часть этого эффекта связана с архитектурным уменьшением разрешения.

Совместный анализ графиков и таблиц показывает, что три семейства моделей различаются не только числом параметров или способом обучения. Они действительно по-разному меняют частотный состав внутренних представлений. ResNet даёт наиболее последовательное снижение центроида. ViT показывает немонотонную динамику на фиксированной решётке патчей. Swin приходит к низкочастотному финальному профилю, но этот результат нужно читать вместе с контролем на уменьшение разрешения.

Практическая значимость работы состоит в том, что предложенный протокол можно использовать как инструмент диагностики внутренних представлений. Он помогает увидеть, насколько быстро модель концентрирует энергию в низкочастотной области, сохраняет ли среднечастотный хвост и где именно по глубине происходят наиболее сильные изменения. Для задач, где пространственная структура признаков особенно значима, такой анализ может быть полезен как дополнительный способ сравнения архитектур. Речь может идти, например, о медицинских изображениях, спутниковых снимках, дефектоскопии, текстурном анализе и задачах с мелкими объектами.

У работы есть ограничения. Спектральная энергия не равна информации в строгом смысле. Она не показывает напрямую, полезен ли кон-

кретный частотный диапазон для классификации. В работе также не анализируется фаза спектра и не проверяется причинная связь между частотным профилем и итоговой точностью модели. Кроме того, в работе не проводились статистические тесты значимости различий между архитектурными семействами: значения $\pm$ стандартное отклонение характеризуют разброс по изображениям, но не доказывают статистическую значимость различий. Ещё одно ограничение связано с ViT и Swin: перевод токенов в двумерную решётку нужен для сопоставления с CNN, но такая решётка не является полной копией свёрточной карты признаков. Токен уже содержит агрегированное описание патча, и это нужно учитывать при интерпретации.

Дальнейшее развитие работы возможно в нескольких направлениях. Во-первых, целесообразно исследовать, как спектральные метрики меняются не только у готовых моделей, но и в процессе обучения. Во-вторых, можно отдельно проверить причинные объяснения: например, сравнить варианты ViT и Swin с изменёнными механизмами внимания, оконной обработкой и объединением патчей. В-третьих, имеет смысл перенести анализ на детекцию и сегментацию, где пространственная локализация признаков имеет большее значение, чем в обычной классификации. Ещё одно направление — анализ связи спектрального профиля с устойчивостью к шуму и сдвигам распределения данных.

Главный итог работы можно сформулировать так: архитектура задаёт не только конечный спектральный профиль представления, но и сам путь перераспределения энергии по глубине. ResNet демонстрирует наиболее устойчивое низкочастотное сжатие, ViT — немонотонное изменение спектрального состава при фиксированной патчевой решётке, Swin — финальный низкочастотный профиль, который частично объясняется уменьшением пространственного разрешения. Именно это различие и является основным результатом проведённого исследования.

Список литературы

- [1] Kaiming He et al. “Deep Residual Learning for Image Recognition”. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, pp. 770–778.
- [2] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. *International Conference on Learning Representations (ICLR)*. 2021.
- [3] Ashish Vaswani et al. “Attention Is All You Need”. *Advances in Neural Information Processing Systems*. Vol. 30. 2017.
- [4] Ze Liu et al. “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021.
- [5] Maithra Raghu et al. “Do Vision Transformers See Like Convolutional Neural Networks?” *Advances in Neural Information Processing Systems*. Vol. 34. 2021, pp. 12116–12128.
- [6] Namuk Park, Songkuk Kim. “How Do Vision Transformers Work?” *International Conference on Learning Representations (ICLR)*. 2022.
- [7] Nasim Rahaman et al. “On the Spectral Bias of Neural Networks”. *Proceedings of the 36th International Conference on Machine Learning*. 2019.
- [8] Zhi-Qin John Xu, Yaoyu Zhang, Tao Luo. “Overview frequency principle/spectral bias in deep learning”. *Communications on Applied Mathematics and Computation* **7** 3 (2025), с. 827–864.
- [9] Jonas Kiessling, Filip Thor. “A computable definition of the spectral bias”. *Proceedings of the AAAI Conference on Artificial Intelligence*. T. 36. 7. 2022, с. 7168–7175.

- [10] Dong Yin et al. “A Fourier Perspective on Model Robustness in Computer Vision”. *Advances in Neural Information Processing Systems*. Vol. 32. 2019.
- [11] Haohan Wang et al. “High-Frequency Component Helps Explain the Generalization of Convolutional Neural Networks”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020, pp. 8684–8694.
- [12] Priye Rana. *Imagenet 10K [Электронный ресурс]*. Набор данных Kaggle. URL: <https://www.kaggle.com/datasets/priyerana/imagenet-10k/data>.
- [13] Jia Deng et al. “ImageNet: A Large-Scale Hierarchical Image Database”. *2009 IEEE Conference on Computer Vision and Pattern Recognition*. IEEE. 2009, pp. 248–255.
- [14] Jason Yosinski et al. “How transferable are features in deep neural networks?” *Advances in Neural Information Processing Systems 27 (NIPS 2014)*. 2014.
- [15] Matthew Tancik et al. “Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains”. *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 7537–7547.
- [16] Muzammal Naseer et al. “Intriguing Properties of Vision Transformers”. *Advances in Neural Information Processing Systems*. Vol. 34. 2021, pp. 23296–23308.
- [17] Sayak Paul, Pin-Yu Chen. “Vision Transformers Are Robust Learners”. *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 2. 2022, pp. 2071–2081.
- [18] Shadi Alijani, Jamil Fayyad, Homayoun Najjaran. “Vision transformers in domain adaptation and domain generalization: a study of robustness”. *Neural computing and applications* **36** 29 (2024), с. 17979–18007.
- [19] Jiawang Bai et al. “Improving Vision Transformers by Revisiting High-Frequency Components”. *arXiv preprint arXiv:2204.00993* (2022).

- [20] Kai Xu и др. “Learning in the frequency domain”. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020, с. 1740—1749.
- [21] Xudong Li и др. “Frequency-domain fusing convolutional neural network: A unified architecture improving effect of domain adaptation for fault diagnosis”. *Sensors* **21** 2 (2021), с. 450.
- [22] Xuyang Liu и др. “Deep learning in spectral analysis: Modeling and imaging”. *TrAC Trends in Analytical Chemistry* **172** (2024), с. 117612.
- [23] Muhammet Fatih Aslan, Busra Aslan, Kadir Sabanci. “Frequency-Domain Vision Transformers: Architectures, Applications, and Open Challenges”. *Applied Sciences* **16** 4 (2026), с. 2024.
- [24] ChunWang Li, JiaLin Guo, Min Zhi. “A Review of Frequency-Domain Transformers in Image Processing Applications”. *2025 4th International Conference on Image Processing, Computer Vision and Machine Learning (ICICML)*. IEEE. 2025, с. 406—411.
- [25] timm. *timm/resnet18.tv_in1k*. https://huggingface.co/timm/resnet18.tv_in1k. Hugging Face model card; ResNet-18 with original TorchVision ImageNet-1K weights. 2025.
- [26] timm. *timm/resnet34.tv_in1k*. https://huggingface.co/timm/resnet34.tv_in1k. Hugging Face model card; ResNet-34 with original TorchVision ImageNet-1K weights. 2025.
- [27] timm. *timm/resnet50.tv2_in1k*. https://huggingface.co/timm/resnet50.tv2_in1k. Hugging Face model card; ResNet-50 with TorchVision IMAGENET1K_V2 weights. 2025.
- [28] timm. *timm/resnet101.tv2_in1k*. https://huggingface.co/timm/resnet101.tv2_in1k. Hugging Face model card; ResNet-101 with TorchVision IMAGENET1K_V2 weights. 2025.
- [29] timm. *timm/vit_tiny_patch16_224.augreg_in21k_ft_in1k*. https://huggingface.co/timm/vit_tiny_patch16_224.augreg_in21k_ft_in1k. Hugging Face model card; ViT-Tiny/16 pretrained on ImageNet-21K and fine-tuned on ImageNet-1K. 2025.

- [30] timm. *timm/vit_small_patch16_224.augreg_in21k_ft_in1k*. https://huggingface.co/timm/vit_small_patch16_224.augreg_in21k_ft_in1k. Hugging Face model card; ViT-Small/16 pretrained on ImageNet-21K and fine-tuned on ImageNet-1K. 2025.
- [31] timm. *timm/vit_base_patch16_224.augreg_in21k_ft_in1k*. https://huggingface.co/timm/vit_base_patch16_224.augreg_in21k_ft_in1k. Hugging Face model card; ViT-Base/16 pretrained on ImageNet-21K and fine-tuned on ImageNet-1K. 2025.
- [32] timm. *timm/vit_large_patch16_224.augreg_in21k_ft_in1k*. https://huggingface.co/timm/vit_large_patch16_224.augreg_in21k_ft_in1k. Hugging Face model card; ViT-Large/16 pretrained on ImageNet-21K and fine-tuned on ImageNet-1K. 2025.
- [33] timm. *timm/swin_tiny_patch4_window7_224.ms_in1k*. https://huggingface.co/timm/swin_tiny_patch4_window7_224.ms_in1k. Hugging Face model card; Swin-Tiny pretrained on ImageNet-1K. 2025.
- [34] timm. *timm/swin_small_patch4_window7_224.ms_in1k*. https://huggingface.co/timm/swin_small_patch4_window7_224.ms_in1k. Hugging Face model card; Swin-Small pretrained on ImageNet-1K. 2025.
- [35] timm. *timm/swin_base_patch4_window7_224.ms_in1k*. https://huggingface.co/timm/swin_base_patch4_window7_224.ms_in1k. Hugging Face model card; Swin-Base pretrained on ImageNet-1K. 2025.
- [36] timm. *timm/swin_large_patch4_window7_224.ms_in22k_ft_in1k*. https://huggingface.co/timm/swin_large_patch4_window7_224.ms_in22k_ft_in1k. Hugging Face model card; Swin-Large pretrained on ImageNet-22K and fine-tuned on ImageNet-1K. 2025.
- [37] Christos Matsoukas и др. “Pretrained vits yield versatile representations for medical images”. *arXiv preprint arXiv:2303.07034* (2023).
- [38] Daquan Zhou et al. “Understanding the Robustness in Vision Transformers”. *Proceedings of the 39th International Conference on Machine Learning*. 2022.

- [39] Ross Wightman. *PyTorch Image Models*. <https://github.com/huggingface/pytorch-image-models>. 2019. DOI: 10.5281/zenodo.4414861.
- [40] Zhi-Qin John Xu и др. *Frequency Principle: Fourier Analysis Sheds Light on Deep Neural Networks*. 2019. arXiv: 1901.06523 [cs.LG]. URL: <https://arxiv.org/abs/1901.06523>.
- [41] Josue Ortega Caro и др. *Local Convolutions Cause an Implicit Bias towards High Frequency Adversarial Examples*. 2020. arXiv: 2006.11440 [cs.LG]. URL: <https://arxiv.org/abs/2006.11440>.
- [42] Hugo Touvron и др. “Training Data-Efficient Image Transformers & Distillation through Attention”. *Proceedings of the 38th International Conference on Machine Learning*. PMLR, 2021, с. 10347—10357. URL: <https://proceedings.mlr.press/v139/touvron21a.html>.
- [43] Ze Liu и др. “Swin Transformer V2: Scaling Up Capacity and Resolution”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, с. 12009—12019. URL: <https://arxiv.org/abs/2111.09883>.
- [44] Peihao Wang и др. “Anti-Oversmoothing in Deep Vision Transformers via the Fourier Domain Analysis: From Theory to Practice”. *International Conference on Learning Representations*. 2022. URL: <https://arxiv.org/abs/2203.05962>.